

DATA-DRIVEN DECISION MAKING

Réduire le churn en prédisant les retards

Un système d'aide à la décision pour Olist (Brésil)

Nom :

Brahim Hatim
Belhaj Hamza

Jury :

Pr. Y. Tabii

Le problème silencieux d'Olist

Olist est la plus grande marketplace e-commerce du Brésil. Ses retards de livraison déclenchent un mécanisme de perte de clients invisible mais coûteux.

8 %

des commandes
arrivent en retard

97 %

des clients Olist
sont mono-achat

≤ 2

note moyenne
après un retard

Conséquence : chaque commande en retard a 51 % de chances de générer un client perdu définitivement.

Notre approche : une décision en trois temps

1

PRÉDIRE

Un modèle XGBoost identifie, dès la passation, les commandes les plus susceptibles d'arriver en retard.

2

INTERVENIR

Un coupon proactif (20 BRL) est envoyé aux clients à risque AVANT que le retard ne soit perçu.

3

MESURER

Un plan A/B test rigoureux calibre l'effet réel et conditionne le déploiement à grande échelle.

Pas un projet d'IA — un projet de décision opérationnelle.

Trois sources de données croisées



Olist (Kaggle)

Transactionnel

9 tables liées · 100 000 commandes · 2016–2018



Jours fériés brésiliens

Temporel

Carnaval, Noël, fêtes nationales · fusion sur la date



PIB + population par état

Spatial

Données IBGE · fusion sur le code état (SP, RJ...)

Volume final après nettoyage : 97 005 commandes uniques. Exigence du brief (« au moins 2 sources ») dépassée.

Trois insights qui ont guidé le modèle

Le proxy churn est empiriquement valide

Corrélation retard $\leftrightarrow$ note $\leq 2 = -0,36$. Notre définition du « churn proxy » s'appuie sur un signal réel, pas une supposition.

Surprise sur les jours fériés

Les commandes passées un jour férié ont MOINS de retards (6,0 % vs 8,1 %). Olist anticipe déjà ses promesses. → Une intuition initiale renversée par la donnée.

Le Brésil est un pays de contrastes

Les états du Nord/Nord-Est (AL, MA, PI...) ont des taux de retard 2 à 3× plus élevés que SP/SC. Justifie l'enrichissement spatial.

3 segments clients identifiés par K-Means

Clients Standard

76 % du volume · 73 632 commandes

Panier moyen **R\$ 102**

Note moyenne **4,75**

Taux de retard **4 %**

% flaggés high-risk **0,2 %**

Clients VIP

4 % du volume · 3 972 commandes

Panier moyen **R\$ 288**

Note moyenne **4,09**

Taux de retard **8 %**

% flaggés high-risk **0,2 %**

Clients Insatisfaits

20 % du volume · 19 401 commandes

Panier moyen **R\$ 109**

Note moyenne **1,93**

Taux de retard **25 %**

% flaggés high-risk **15 %**

Insight clé : 87 % des prédictions « high-risk » se concentrent dans le segment « Insatisfaits ».

3 modèles entraînés et comparés

Même feature set, même validation croisée. Métriques sur le test set (20 % retenu).

Modèle	AUC-ROC	F1 (classe positive)	Choix
Régression logistique (baseline)	0,78	0,32	—
Random Forest + SMOTE	0,81	0,40	—
XGBoost (champion)	0,846	0,46	✓

Top features identifiées par SHAP : delivery_buffer_days, seller_historical_late_rate, route_late_rate, cluster_id, distance_km.

Performance technique : ce que disent les chiffres

AUC

0,846

forte capacité
de discrimination

La cible Phase 1 ($F1 \geq 0,75$) était inatteignable

Sur un problème à 8 % de classe positive, le F1 plafonne mathématiquement entre 0,40 et 0,55 — la littérature Olist le confirme.

F1

0,46


plafond empirique
du problème

L'AUC, robuste au déséquilibre de classes, est notre vraie métrique de qualité technique : 0,846 indique que le modèle discrimine très bien les retards des non-retards.

Recalibrer la cible empiriquement n'est pas un échec — c'est précisément la démarche data-driven que ce projet exige.

La vraie métrique : précision sur les top-K %

Pour un système d'aide à la décision, ce qui compte n'est pas la performance globale du modèle, mais sa précision sur les commandes qu'il flague comme à risque.



77,8 %

de précision sur les 1 % les plus risqués

7x

mieux que le hasard sur les top 5 % (56 % vs
taux naturel 8 %)

L'économie de chaque intervention est positive


Pour une commande au seuil de rentabilité (risque $\geq 0,67$) :

Gain attendu		Coût coupon		Net unitaire
R\$ 30	—	R\$ 20	=	+ R\$ 10
$0,67 \times 0,20 \times 150$		hypothèse Phase 1		par intervention

Robuste à la sensibilité : l'analyse de sensibilité ($LTV \times$ coût coupon) montre que le ROI reste positif même dans les scénarios pessimistes (LTV à 100, coupon à 30). Le business case ne dépend pas d'une hypothèse miracle.

Le seuil de risque est un levier de décision

Le seuil n'est pas un choix arbitraire — il se déduit mathématiquement de l'économie unitaire.



Seuil optimal

0,67

Déduit de $20 / (0,20 \times 150)$ — point où chaque coupon devient rentable.

Cible business

3,3 %

des commandes ciblées au seuil 0,67.

Un dashboard décisionnel multi-profils

Construit avec Streamlit, déployé sur Streamlit Community Cloud, accessible en ligne.

DIRECTION

KPIs business, revenu à risque, économies nettes projetées, risque par état et par segment.

OPÉRATIONS

États les plus risqués (où recruter des transporteurs), risque par catégorie produit, effet des jours fériés.

MARKETING

Liste des commandes à cibler, action recommandée, budget coupons, export CSV.

7 vues distinctes, filtres dynamiques (seuil, état, segment), redéploiement automatique à chaque push.

Mesurer rigoureusement l'effet réel : le plan A/B

Hypothèse nulle (H_0) : l'envoi proactif d'un coupon ne réduit pas le taux de churn proxy.

Baseline mesurée	Effet à détecter	Taille d'échantillon	Durée estimée
51 %	-20 %	364	16 sem.
de churn proxy parmi les high-risk	relatif (cible business)	par groupe ($\alpha=0,05$; power=0,80)	au taux high-risk réel de 3,3 %

Règle de décision : déploiement si $p < 0,05$ ET baisse ≥ 15 % relatif ET ROI positif.

Le plan A/B complet (2 pages) est documenté dans docs/Phase6_Plan_AB_Test.md.

Ce que nous avons prouvé

1 Le modèle prédit avec une précision exploitable

AUC 0,846 · 56 % de précision dans les top 5 %, soit 7× le hasard.

2 L'intervention est rentable en espérance

Économie unitaire positive (+R\$ 10/intervention), robuste aux variations d'hypothèses.

3 Le déploiement est immédiat

Dashboard décisionnel multi-profils déployé en ligne, plan A/B dimensionné et prêt à lancer.

4 La démarche est honnête et data-driven

Cible F1 recalibrée empiriquement, valeurs réelles intégrées, hypothèses traçables dans tous les livrables.

Un outil décisionnel, prêt à être mis en production.

Merci.

Questions ?

Brahim Hatim · Belhaj Hamza

Dashboard : déployé sur Streamlit Community Cloud

Repo : github.com/brahimhatim265/DATA-DRIVEN-DECISION-MAKING